

Point Cloud 입력 신경망 기반 로봇 매니퓰레이터 패스 플래닝

Robot Manipulator Path Planning using Point Cloud Input Neural Network

이정우¹ · 김송우¹ · 박찬진¹ · 현승민¹ · 정호진¹ · 윤한얼²

Jungwoo Lee, Songwoo Kim, Chanjin Park, Seungmin Hyun, Ho-Jin Jung and Han Ul Yoon

¹연세대학교 일반대학원 전산학과

E-mail: {jw.lee, swkim, cjpark04, smhyun, hojinj}@yonsei.ac.kr

²연세대학교 소프트웨어학부

E-mail: huyoon@yonsei.ac.kr

요 약

본 논문은 point cloud를 입력으로 하는 신경망을 통하여 장애물이 존재하는 환경에서 로봇 매니퓰레이터를 패스 플래닝하는 방법에 대해 논한다. 일반적으로 point cloud 기반 로봇 매니퓰레이션은 데이터로부터 workspace 장애물 식별, free configuration 계산, 패스 생성, 수행의 단계로 이루어진다. 이 과정을 신경망을 통해 end-to-end 방식으로 구현할 수 있다면, 다양한 환경과 로봇의 타입에 유연하게 적용할 수 있다. 따라서, 본 연구에서는 configuration space에 cost를 할당하는 c2g-HOF 신경망을 소개하고, 이를 6-DoF 매니퓰레이터에 적용한 패스 플래닝을 시도한다. 가상현실에서 학습용 point cloud 데이터를 획득하고, 획득된 데이터를 이용하여 c2g-HOF를 학습시켜, 6-DoF 매니퓰레이터의 패스를 생성하여 적용해본다. 최종적으로, 실제 환경의 로봇을 통해 다양한 장애물이 있는 환경에서 패스 플래닝의 수행 가능성을 논한다.

키워드 : Point Cloud, c2g-HOF 신경망, 로봇 매니퓰레이터, 패스 플래닝

1. 서 론

로봇 패스 플래닝 문제란 initial configuration으로부터 goal configuration까지의 free configuration space상에서의 연속적인 커브를 찾는 문제이다. 따라서, 환경에 장애물이 복잡하게 놓여있고, 로봇 매니퓰레이터의 DoF가 높아질수록 패스 플래닝 문제를 풀기가 어려워진다[1].

Point cloud 데이터는 환경에 대한 정보를 3d voxel형태로 제공하므로, workspace상의 장애물 및 공간을 파악하기에 매우 유용하다. Huh는, point cloud를 입력으로 하는 신경망을 통해 비교적 높은 DoF를 가진 로봇 매니퓰레이터의 패스 플래닝을 end-to-end 방식으로 수행할 수 있는 c2g-HOF를 제시하였다[2]. 이로부터 샘플링 기반 알고리즘인 RRT 및 RRT-smooth에 비해 시간적인 이점이 있음을 보였으며, 특히 RRT에 비해 더 짧은 경로를 얻는다는 결과를 보였다[3-4].

본 논문에서는 6-DoF 로봇 매니퓰레이터(Kinova Gen2, Kinova, Boisbriand QC, Canada)에 c2g-HOF를 적용하여, 장애물이 있는 환경에서 패스 플래닝을 수행하고 그 결과를 확인해본다. 또한, 실제 로봇 매니퓰레이터의 플래닝에 적용하기 위해 고려되어야 할 사항들에 대해 논한다.

2. 제안하는 방법론

2.1 c2g-HOF 학습을 위한 데이터셋 사전 준비

[2]에서 제안된 c2g-HOF의 학습을 위한 데이터셋을 구성하기 위한 과정은 아래와 같이 요약된다:

- 1) 먼저, c2g-HOF의 학습을 위한 point cloud 데이터를 시뮬레이션 환경에서 획득한다.
- 2) Point cloud 데이터로 표현되는 workspace에 대한 free configuration space를 grid-based로 표현한다.
- 3) Free configuration space에 wave front 기반 플래너를 적용하여 goal configuration까지의 cost-to-go를 할당한다.
- 4) 이후, 획득된 point cloud 데이터, free configuration space, 그리고 cost-to-go map을 가지고 c2g-HOF를 학습한다.
- 4) 학습된 c2g-HOF를 통해 Kinova Gen2의 패스 플래닝을 수행한다.

그림 1은 위의 과정 1)~과정 2)를 위해 Unity에서 구성한 실험 환경을 보여준다. c2g-HOF를 활용하여 로봇 매니퓰레이터의 패스 플래닝을 수행하기 위해, workspace와 configuration space의 정보를 담은 학습용 데이터셋을 다음과 같은 5개의 필드(차원)로 구성한다: <장애물의 좌표(장애물 개수×3), 장애물의 크기(장애물 개수×3), 장애물의 point cloud(10000×3), configuration space에서 샘플링한 좌표(5000×3), configuration space 점들 사이의 cost(500×5000)>. 이를 Unity를 이용하여 획득하고, c2g-HOF의 학습 데이터셋으로 이용하여 매니퓰레이터가 패스 플래닝을 수행할 수 있도록 한다.

감사의 글 : 이 성과는 정부(산업통상자원부,과학기술정보통신부)의 재원으로 한국산업기술기획평가원 "실외 과수환경에서 1분에 3개 이상 연속적인 과실 수확과 다중운반로봇 관제가 가능한 농작업 로봇플랫폼 개발(과제번호: 20023014)" 및 정보통신기획평가원의 "SW 중심대학 지원사업(과제번호: 2019-0-01219)"의 연구결과로 수행되었습니다. 연구비 지원에 감사드립니다.




그림 1. c2g-HOF 네트워크 학습을 위한 데이터 획득을 위한 Unity 가상 환경 구축

Fig. 1. Virtual reality environment in Unity3d for acquiring data sets to train the c2g-HOF network.

2.2 패스 플래닝을 위한 c2g-HOF 네트워크 구조

그림 2는 c2g-HOF의 파이프라인을 보여준다[2]. 해당 네트워크는 workspace의 point cloud를 입력으로 받으며, cost-to-go value를 출력한다. c2g-HOF는 c2g-generating-HOF와 c2g network로 이루어져 있다. c2g-generating-HOF는 workspace의 point cloud를 입력으로 받는 PointNet 인코더 구조이며, 이 네트워크의 출력은 평균과 분산으로, 뒤에 연결되어 있는 c2g network 내부의 radial basis function을 세팅하기 위한 weight로 사용된다 [5]. c2g network는 radial basis function network(RBFN)이며 학습이 진행됨에 따라 임의의 configuration에서부터 goal configuration까지의 cost를 출력할 수 있게 된다. [2]에 따르면, 7-DoF 로봇 매니퓰레이터 Kinova Gen3에 대한 c2g-HOF의 패스 플래닝 성능의 검증을 위해, 세 개의 각기 다른 workspace에서, 10개의 경로 생성에 소요된 시간의 총합을 비교한 결과, PRM보다 약 31배, RRT보다 약 113배 빠른 성능을 보이는 것으로 알려져 있다.

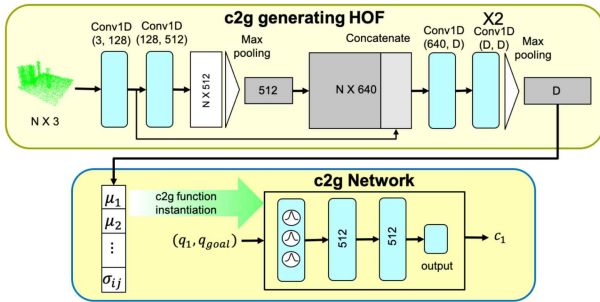


그림 2. c2g-HOF(입력: point cloud, 출력: cost-to-go value)의 파이프라인[2]

Fig. 2. c2g-HOF pipeline(input: point cloud, output: cost-to-go value)

3. 실험 및 결과

2.1절에서 보았던 그림 1과 같이 데이터 사전 준비를 위해 다수의 Kinova Gen2 모델을 배치하였다. 본 논문에서는 이와 같은 구성으로 총 50개의 장면에서 500개의 goal에 대해 데이터를 획득하였다. 정답 데이터는, 구한 데이터셋에서 configuration space를 균등하게 나누어 충돌이 없는 점들끼리 그래프 노드를 형성한 뒤, 그래프에 속한 각기 다른 노드들로부터 골 노드까지의 최단 경




그림 3. c2g-HOF에 의해 플래닝된 패스를 따라 로봇 매니퓰레이터가 initial configuration에서 goal configuration에 도달하는 과정

Fig. 3. A robotic manipulator is approaching from the initial configuration to the goal configuration via a planned path generated by c2g-HOF.

로를 구하는 방법을 이용하였다. cost로는 해당 노드에 도달하기까지 거처온 총 노드의 개수를 할당하였다.

그림 3은 c2g-HOF에 의해 플래닝된 패스를 따라 로봇 매니퓰레이터가 initial configuration에서 goal configuration에 도달하는 과정을 순서대로 나타낸다. 로봇의 엔드 이펙터는 과란 점에서 시작하여 빨간 점에 도달하는 경로를 c2g-HOF 네트워크로 획득하였다. 실험 결과, point cloud 데이터의 입력만으로 시작 지점으로부터 목표 지점까지 장애물과 충돌하지 않는 경로를 성공적으로 생성하고 움직이는 모습을 볼 수 있다.

4. 결론 및 향후 연구

본 논문에서는 c2g-HOF를 통해 장애물이 있는 환경에서 로봇 매니퓰레이터인 Kinova Gen2의 패스 플래닝을 진행하였으며, 이때 가상 환경인 Unity를 이용하여 데이터셋을 생성하고 c2g-HOF의 학습에 이용하였다. 가상 현실에서의 시뮬레이션 테스트 결과, 장애물이 있는 환경에서 goal configuration으로 패스 플래닝을 성공적으로 수행하는 모습을 확인할 수 있었다.

향후 이 연구를 장애물이 움직이는 동적 상황에 적용하여, 매번 업데이트가 이루어지는 환경 속에서도 효율적으로 경로를 생성하여 로봇 매니퓰레이터가 패스 플래닝을 수행할 수 있는지 검증하고 기존 방법들과의 성능 비교를 진행할 예정이다.

참 고 문 헌

- [1] S. M. LaValle, *Planning algorithms*. Cambridge University press, 2006.
- [2] J. Huh et al, "Cost-to-Go Function Generating Networks for High Dimensional Motion Planning," in *Proc. of IEEE Int'l Conf on Robotics and Automation (ICRA)*, Xi'an, China, May. 30 - Jun. 5, 2021, pp. 8480-8486.
- [3] S. Karaman et al, "Anytime Motion Planning using the RRT*," in *Proc. of IEEE Int'l Conf on Robotics and Automation (ICRA)*, Shanghai, China, May 9-13, 2011, pp. 1478-1483.
- [4] R. Geraerts et al, "Creating High-quality Paths for Motion Planning," *The International Journal of Robotics Research (IJRR)*, vol. 26, no. 8, pp. 845-863, 2007.
- [5] C. Qi et al. "Pointnet: Deep learning on point sets for 3d classification and segmentation," in *Proc. of the IEEE Conf on Computer Vision and Pattern Recognition (CVPR)*, Honolulu, Hawaii, July 22-25, 2017, pp. 845-863.